Antes

Antes de empezar

Tu turno en MICAI 2026

Jueves 5 de noviembre
16:40 h · Room 1104

Sesión *Machine Learning & Data Analytics* (16:00–18:20), Tec de Monterrey, Campus Chihuahua. Paper ID **78**. 10 min + 5 de preguntas. Tu meta: 8:31.

Antes de tu turno

- El programa puede cambiar: revísalo el miércoles en la noche y el jueves en la mañana (micai.org/2026/activities).
- Llega a la sala a las **15:45** y quédate desde el inicio: de 16:20 a 16:40 el programa está vacío y podrían adelantarte.
- Busca al moderador y dile: **Good afternoon. We are presenting paper 78. May we load our slides?** gud af-ter-NÚN. ui ar pri-SÉN-ting PÉI-per SÉ-ven-ti ÉIT. mei ui LOUD áur SLÁIDS?
- Carga el .pptx de la USB y revisa las diapositivas 5 y 9 (tienen gráficas). Si algo se ve mal, usa el .pdf.
- Cronómetro a la vista, celular en silencio, agua cerca.

Quién dice qué

- **Expositor 1 (Baruc Polvo):** 1, 2, 3, 4, 10, 11.
- **Expositor 2 (David Reyes):** 5, 6, 7, 8, 9.
- Separa las tarjetas por color. Las de preguntas sirven a los dos: imprímelas dos veces.

Cómo leer las tarjetas

- Cada renglón es una pausa: habla despacio, los nervios aceleran.
- ► *Naranja:* qué hacer; no se lee.
- 0.399 gris: la cifra que se ve en pantalla; no se lee.
- ✂ La frase se puede saltar si vas tarde.
- Números: 0.404 = *zero point four zero four* · 15.5 % = *fifteen point five percent*.

Para imprimir

Tamaño real (100 %), a una cara, hoja carta. Corta por la línea punteada.

1

A Benchmark of Five Machine-Learning Architectures…

Diapositiva 1 de 11 · minuto 0:00 → **0:31**

EXPOSITOR 1
Baruc

► *Respira y mira al público*

Good afternoon, everyone.

My name is Baruc Polvo,
and this is my colleague David Reyes.

We are from ESCOM,
at the Instituto Politécnico Nacional,
in Mexico City.

Today we present a benchmark
of five machine learning models
for daily trading signals.

Pronuncia: afternoon af-ter-NÚN · **everyone** ÉV-ri-uan · **benchmark** BÉNCH-mark · **machine learning** ma-SHÍN LÉR-ning · **trading signals** TRÉI-ding SÍG-nals · **colleague(s)** CÓ-lig(s)

Idea: Saludo, quién soy, de dónde vengo y de qué trata.

CLIC ▶ 2

2 Do deep networks beat simple models?

Diapositiva 2 de 11 · minuto 0:31 → **1:21**

EXPOSITOR 1
Baruc

Our question is simple:
do deep networks beat simple models
for daily trading signals?

Many papers compare
only one or two models.

They often report accuracy or RMSE.
These numbers do not tell us
if a strategy makes money.

And many papers remove features
with statistical filters,
but they do not check if this helps.

So we made a **fair test** with five models,
measured as classification
and as a trading strategy.

Pronuncia: deep networks DIP NÉT-uorks · **accuracy** Á-kiu-ra-si · **RMSE** ar-em-es-Í · **features** FÍ-chers · **statistical** sta-TÍS-ti-cal · **measured** MÉ-shurd · **classification** cla-si-fi-KÉI-shon · **strategy** STRÁ-te-yi

Idea: La pregunta y los 3 huecos de otros artículos. Nuestra meta: una prueba justa.

CLIC ▶ 3

3 One signal per day, seven tech stocks

Diapositiva 3 de 11 · minuto 1:21 → **2:23**

EXPOSITOR 1
Baruc

We use seven big tech stocks:
Apple, NVIDIA, Tesla, Amazon,
Microsoft, Google and Meta.

The data is free, from Yahoo Finance,
from 2013 to 2025.

Every day, each stock gets one label:
buy, hold or sell.

We compare tomorrow's return
with the last **252** days.

Top 30 percent: the label is buy.
Bottom 30 percent: the label is sell.
The rest is hold.

► *Señala BUY, SELL y HOLD*

So the label changes with the volatility,
and it only uses past data.

> ✂ The input is 61 features:
> technical indicators,
> plus the S&P 500 and the VIX.

Pronuncia: NVIDIA en-VÍ-dia · **Yahoo Finance** YÁ-ju FÁI-nans · **2013** tuén-ti zer-TÍN · **2025** tuén-ti tuén-ti FÁIV · **label** LÉI-bel · **tomorrow's return** tu-MÓ-rous ri-TÉRN · **252** tu JÁN-dred FÍF-ti TU · **volatility** vo-la-TÍ-li-ti · **S&P 500** es-and-PÍ FÁIV JÁN-dred · **VIX** VIKS

Idea: Qué acciones, qué datos y cómo se etiqueta (30/40/30) sin ver el futuro.

CLIC ▶ 4

4 Five models, one protocol

Diapositiva 4 de 11 · minuto 2:23 → **3:19**

EXPOSITOR 1
Baruc

We compare **five models**.

Two classical models:
logistic regression and XGBoost.

And three deep networks:
an LSTM, a one-dimensional CNN,
and a hybrid CNN-LSTM.

We use three splits.
All of them test on the same year, **2025**.
Only the training history changes:
ten, six or four years.

► *Señala las barras*

We train one global model
and one model per stock.
In total, **120 runs**.

Our main metric is macro-F1,
and we also simulate
a simple trading strategy.

→ Now, my colleague will show the results.

Pasa la palabra. David sigue con la diapositiva 5.

Pronuncia: logistic regression lo-YÍS-tic ri-GRÉ-shon · **XGBoost** ex-yi-BÚST · **LSTM** el-es-ti-ÉM · **one-dimensional** uán-di-MÉN-sho-nal · **CNN** si-en-ÉN · **hybrid** JÁI-brid · **history** JÍS-to-ri · **120** uán JÁN-dred TUÉN-ti · **macro-F1** MÁ-cro ef-UÁN · **simulate** SÍ-miu-leit

Idea: 5 modelos, 3 particiones, la misma prueba en 2025, 120 corridas.

CLIC ▶ 5

5 Result 1 · Logistic regression leads on average

Diapositiva 5 de 11 · minuto 3:19 → **4:20**

EXPOSITOR 2
David

Thank you. Here is the **first result**.

Each group is one split.
The blue bar is logistic regression.

► *Señala una barra azul*

It has the best average macro-F1:
zero point three nine nine. 0.399

It wins in splits A and C.
In split B, XGBoost is very slightly better.

The dashed line is random guessing:
zero point three three three. 0.333

► *Señala la línea punteada*

So the signal is small, but it is there.

In the trading simulation of split B,
logistic regression is the best:
Sharpe ratio **zero point seven six**, 0.76
and profit factor **one point two one**. 1.21

Pronuncia: average Á-ve-rich · **slightly** SLÁIT-li · **dashed line** DASHT LÁIN · **random guessing** RÁN-dom GUÉ-sing · **simulation** si-miu-LÉI-shon · **Sharpe ratio** SHARP RÉI-shio · **profit factor** PRÓ-fit FÁC-tor

Idea: La LR gana en promedio (0.399) y en la simulación. La señal es pequeña, pero real.

CLIC ▶ 6

6 **Result 2 · Do not pre-filter the features**
Diapositiva 6 de 11 · minuto 4:20 → **4:51**

EXPOSITOR 2
David

Second result.

Many studies filter the features
before training.

We tested the common filters:
Pearson, VIF, SHAP and Spearman.

In **eleven of fifteen** cases, 11 / 15
► *Señala el 11 / 15*
keeping all 61 features was better.

The model's own regularization
selects features better
than an external filter.

Pronuncia: filter FÍL-ter · **Pearson** PÍR-son · **VIF** vi-ai-ÉF · **SHAP** SHAP · **Spearman** SPÍR-man · **eleven** i-LÉ-ven · **fifteen** fif-TÍN · **regularization** re-guiu-la-ri-SÉI-shon · **external** ex-TÉR-nal

Idea: En 11 de 15 casos conviene dejar las 61 variables.

CLIC ▶ 7

7 **Result 3 · The stock matters more than the model**
Diapositiva 7 de 11 · minuto 4:51 → **5:33**

EXPOSITOR 2
David

Third result.

We split the variation of the Sharpe ratio.

The stock explains
fifteen point five percent. 15.5 %
The model explains only
three point four percent. 3.4 %

So, choosing the stock matters
about **four and a half times** more
than choosing the model.

> ✂ For example, Amazon does well
> with almost any model,
> and Google does badly
> with almost any model.

Pronuncia: variation ve-ri-ÉI-shon · **explains** ex-PLÉINS · **fifteen point five** fif-TÍN point FÁIV · **three point four** ZRI point FOR · **choosing** CHÚ-sing · **Amazon** Á-ma-zon · **Google** GÚ-gol

Idea: La acción pesa 4.5 veces más que el modelo.

CLIC ▶ 8

8 Was it fair? We rebuilt the protocol

Diapositiva 8 de 11 · minuto 5:33 → **6:17**

EXPOSITOR 2
David

But was the comparison **fair**?
The reviewers asked a good question.

XGBoost had a bigger search,
and the input window of the networks
was chosen on the test set.

So we rebuilt everything.

► *Señala dev y final*

All decisions use 2024.
The test year, 2025, is used only one time.

All five models use
the same search tool, Optuna,
and the same **1,736** test rows.

Pronuncia: fair FER · **reviewers** ri-VIÚ-ers · **search** SERCH · **chosen** CHÓU-sen · **rebuilt** ri-BÍLT · **2024** tuén-ti tuén-ti FOR · **Optuna** op-TÚ-na · **1,736** uán ZÁU-sand SÉ-ven JÁN-dred ZÉR-ti SIKS

Idea: Lo rehicimos sin ventajas: todo se decide con 2024; 2025 se usa una sola vez.

CLIC ▶ 9

9 Result 4 · The gap does not close

Diapositiva 9 de 11 · minuto 6:17 → **7:09**

EXPOSITOR 2
David

And the result?
The gap does not close.

Logistic regression gets
zero point four zero four, 0.404
with a 95 percent confidence interval
from zero point three seven nine 0.379
to zero point four two eight. 0.428

It is **significantly better**
than the other four models.

The validation loss of the networks
never goes clearly below the random level.

> ✂ A very small LSTM
> gives the same result as a big one.

→ Now my colleague will explain why.

Pasa la palabra. Baruc sigue con la diapositiva 10.

Pronuncia: 95 NÁIN-ti FÁIV · **confidence interval** CÓN-fi-dens ÍN-ter-val · **significantly** sig-NÍ-fi-cant-li · **validation loss** va-li-DÉI-shon LOS · **clearly** CLÍR-li · **level** LÉ-vel

Idea: Aun con una búsqueda justa, la LR sigue arriba: 0.404, significativamente mejor.

CLIC ▶ 10

10 Why does a linear model win here?

Diapositiva 10 de 11 · minuto 7:09 → **7:57**

EXPOSITOR 1
Baruc

Thank you.
Why does a simple linear model
win here?

First, the data is small for deep models:
about ten thousand rows.

Second, the one-day label is very noisy.

Third, our features
already summarize many days,
so a linear model can use them well.

We also have **limitations**:
we test only one year,
we do not include transaction costs,
and we use only seven stocks
from one sector.

Pronuncia: linear LÍ-ni-ar · **thousand** ZÁU-sand · **noisy** NÓI-si · **summarize** SÁ-ma-rais · **limitations** li-mi-TÉI-shons · **transaction costs** tran-SÁC-shon COSTS · **sector** SÉC-tor

Idea: Pocos datos, etiqueta con ruido, variables que ya resumen. Y nuestras limitaciones.

CLIC ▶ 11

11 Takeaways · Thank you · Questions?

Diapositiva 11 de 11 · minuto 7:57 → **8:31**

EXPOSITOR 1
Baruc

To finish, **three messages**.

One: a well-regularized logistic regression
is a strong and cheap baseline.

Two: do not filter the features
before training.

Three: the stock matters
more than the model.

Our code and data are public.
Thank you.
We are happy to answer your questions.

Pronuncia: messages MÉ-si-yis · **well-regularized** uel RÉ-guiu-la-raisd · **cheap** CHIIP · **baseline** BÉIS-lain · **public** PÁ-blic · **questions** CUÉS-chons

Idea: Los tres mensajes y gracias. Deja esta diapositiva puesta durante las preguntas.

Deja esta diapositiva

? Preguntas: índice

5 minutos después de exponer

Cómo contestar

- Deja puesta la diapositiva 11: ahí está el enlace al código.
- Escucha una **palabra clave**. Si no la oíste, pide que repitan.
- Busca la letra de abajo y lee la respuesta corta.
- Si piden una cifra exacta: tarjeta **Cifras**.
- Contesta corto. Si no sabes: **We can talk more after the session.**

Por tema

A **¿La señal es real?**
signal · random · overlap · intervals · bootstrap · block

B **¿Por qué gana la LR?**
why linear · deep networks · Transformer · GRU · elastic net · L2

C **¿Fue justo?**
fair · search · look-back · window · leakage · look-ahead

D **Limitaciones**
one year · 2025 · costs · transaction · survivorship · bias

E **Decisiones de diseño**
accuracy · macro-F1 · one day · horizon · global · per stock

F **Uso y siguiente paso**
trade · real money · reproduce · code · future work · next steps

Diapositivas de respaldo

- **12** + Enter: Corrected protocol, full Table 6 (hyper-parameters, intervals, Sharpe).
- **13** + Enter: Since submission: six test years, transaction costs, unseen 2026 data.
- **14** + Enter: Benchmark tables 3–5 (global, economics, per-stock).
- **15** + Enter: Hyper-parameter search: trials and search space per model.

Ayuda Frases y emergencias

Para cualquier momento

Frases de apoyo

Sorry, could you repeat the question, please?
SÓ-ri, cud yu ri-PÍT de CUÉS-chon, plis? · ¿Perdón, puede repetir la pregunta, por favor?

Could you speak a little more slowly, please?
cud yu SPIK a LÍ-tel mor SLÓU-li, plis? · ¿Podría hablar un poco más despacio?

You are asking about transaction costs, right?
yu ar ÁS-king a-BÁUT …, ráit? · ¿Pregunta por los costos, verdad? (repite la palabra clave para ganar tiempo)

Thank you for the question.
ZÉNK yu for de CUÉS-chon. · Gracias por la pregunta.

That is a good question. My colleague will answer.
dat is a gud CUÉS-chon. mai CÓ-lig uil ÁN-ser. · Buena pregunta. Mi colega va a responder.

We have more details in the paper.
ui jav mor DÍ-teils in de PÉI-per. · Tenemos más detalles en el artículo.

We did not test that. It is future work.
ui did not test dat. it is FIÚ-cher uork. · No lo probamos. Es trabajo futuro.

Let me show you a backup slide.
let mi SHOU yu a BÁK-ap slaid. · Le muestro una diapositiva de respaldo.

We can talk more after the session.
ui can tok mor ÁF-ter de SÉ-shon. · Podemos platicar más al final de la sesión.

Si el moderador te dice…

- **“Two minutes left.”** Salta lo marcado con ✂ y sigue.
- **“Please wrap up.” / “Please finish.”** Escribe 11 + Enter y di los tres mensajes.
- **“You only have five minutes.” / “We are late.”** Usa la tarjeta de la versión corta.
- **“Time is up.”** Di “Thank you” y termina.

Si algo falla

- **No abre el .pptx o se ve mal:** abre el .pdf de la USB.
- **Te perdiste:** lee el título de la diapositiva y busca la tarjeta con ese número.
- **Se te fue una palabra:** señala la gráfica y di el número.

A ¿La señal es real?

Preguntas probables

David Si oyes: **signal · random · luck · efficient market**

Is there a real signal, or is it random?

Yes, there is a signal, but it is small.
Logistic regression gets **0.404**.
Random is **0.333**.
The confidence interval does not include **0.333**.
We do not say that you can make money with it.

Sí hay señal, pero es pequeña; el intervalo no incluye el azar. No decimos que se pueda ganar dinero con ella.

David Si oyes: **overlap · intervals · significant**

The intervals overlap. Why do you say significant?

Because we test paired differences, on the same rows.
Logistic regression minus each model has an interval that does not include zero.
For example, plus **0.045** against XGBoost.

Porque probamos diferencias pareadas, en las mismas filas; el intervalo de la diferencia no incluye el cero.

► *Ayuda: 12 + Enter. Di: Let me show you a backup slide.*

David Si oyes: **bootstrap · block · resamples**

What kind of bootstrap did you use?

A block bootstrap on the test rows: blocks of **20** rows and **2,000** resamples.
We use blocks because the days are not independent.

Bootstrap de bloques: bloques de 20 filas y 2,000 remuestreos, porque los días no son independientes.

B ¿Por qué gana la LR?

Preguntas probables

Baruc Si oyes: **why linear · deep networks · overfitting**

Why does a linear model beat deep networks?

The data is small for deep models, the one-day label is very noisy, and our features already summarize many days.
The validation loss of the networks stays near the random level, and a small LSTM does the same as a big one.

Pocos datos, etiqueta con ruido y variables que ya resumen. La pérdida de validación se queda cerca del azar.

► *Ayuda: 10 + Enter.*

David Si oyes: **Transformer · GRU · random forest · SVM · other models**

Why not Transformers, GRU or other models?

We did not test them.
We chose a linear model, a tree model and three sequence networks.
Transformers need much more data.
In our tests, very different networks give the same result, so the limit is the data, not the architecture.

No los probamos. Los Transformers necesitan muchos más datos. Redes muy distintas dan lo mismo: el límite son los datos.

Baruc Si oyes: **elastic net · L2 · C · regularization**

Which regularization did you use?

In Section 7 we use elastic net.
In Section 8, Optuna could choose L1, L2 or elastic net.
It chose L2 with very strong regularization:
C equal to **0.000165**.

Elastic net en la §7. En la §8 Optuna eligió L2 con regularización muy fuerte: C = 0.000165.

► *Ayuda: 15 + Enter. Di: Let me show you a backup slide.*

C ¿Fue justo?

Preguntas probables

David Si oyes: **fair · search · tuning · hyper-parameters**

Did the deep models get a fair hyper-parameter search?

Yes.

In Section 8 all models use the same Optuna sampler, the same decision year and the same test rows.

The networks search **17** to **20** hyper-parameters.

The gap is bigger, not smaller.

Sí: mismo muestreador, mismo año de decisión y mismas filas. Las redes buscan 17 a 20 hiperparámetros y la diferencia crece.

► *Ayuda: 15 + Enter. Di: Let me show you a backup slide.*

David Si oyes: **look-back · window · test set · oracle**

Was the look-back chosen on the test set?

Yes, in Section 7, and we say it in the paper.

It helps the networks, not logistic regression.

Section 8 removes this problem.

Sí, en la §7, y el artículo lo dice. Favorece a las redes. La §8 lo quita.

Baruc Si oyes: **leakage · look-ahead · future data · scaler · bidirectional**

Is there data leakage?

The label thresholds use only past data, shifted by one day.

The scalers are fitted on the training data.

In Section 8, no decision uses **2025**.

And a bidirectional LSTM only reads a closed window of past days.

Umbrales con datos pasados, escaladores ajustados con entrenamiento, ninguna decisión con 2025. La LSTM bidireccional solo lee días pasados.

D Limitaciones

Preguntas probables

David Si oyes: **one year · 2025 · special · walk-forward**

You test only one year. Is 2025 special?

It is our main limitation. **2025** is not an easy year: the return is below the median and the volatility is high.

After the paper, we tested six years, **2020** to **2025**.

Logistic regression and XGBoost are similar, and both are better than the networks.

Es la limitación principal. Después del artículo probamos seis años: LR y XGBoost son parecidos y superan a las redes.

► *Ayuda: 13 + Enter. Di: Let me show you a backup slide.*

David Si oyes: **costs · transaction · fees · slippage**

What about transaction costs?

They are not in the paper.

After the paper we tested **10** basis points.

Logistic regression keeps a Sharpe ratio of **0.62**.

XGBoost goes to almost zero, because it trades more.

No están en el artículo. Con 10 puntos base la LR conserva Sharpe 0.62 y XGBoost cae casi a cero porque opera más.

► *Ayuda: 13 + Enter. Di: Let me show you a backup slide.*

Baruc Si oyes: **survivorship · bias · only tech · other markets**

What about survivorship bias? Only seven tech stocks.

Yes, it is a limitation.

We compare models on the same data.

We do not say the results are true for the whole market.

Sí, es una limitación. Comparamos modelos con los mismos datos; no decimos que valga para todo el mercado.

E Decisiones de diseño

Preguntas probables

Baruc Si oyes: **accuracy · macro-F1 · why this metric**

Why macro-F1 and not accuracy?

If a model always says hold, the accuracy is about **40** percent.

Macro-F1 gives the same weight to buy, hold and sell.

Si un modelo siempre dice mantener, la exactitud es de 40 %. F1-macro le da el mismo peso a las tres clases.

Baruc Si oyes: **one day · horizon · percentile · 30/70 · label**

Why a one-day horizon and this label?

We want a daily signal, and one day is the most difficult case.

The percentiles adapt to the volatility, so we do not choose a fixed threshold.

Longer horizons are a different problem, for future work.

Queremos una señal diaria y es el caso más difícil. Los percentiles se adaptan a la volatilidad. Otros horizontes son trabajo futuro.

David Si oyes: **global · per stock · one model**

Global model or one model per stock?

We tested both.

The global model has seven times more data, and it is better or equal.

Probamos los dos. El global tiene siete veces más datos y es mejor o igual.

F Uso y siguiente paso

Preguntas probables

Baruc Si oyes: **trade · real money · profit · buy and hold**

Can people use this to trade?

It is a comparison, not a trading system.

We do not say that it beats the market.

But for daily data, a simple regularized model is a good starting point.

Es una comparación, no un sistema de inversión. No decimos que le gane al mercado. Un modelo simple regularizado es un buen punto de partida.

Baruc Si oyes: **reproduce · code · data · GitHub**

Can I reproduce your results?

Yes.

The data is free from Yahoo Finance.

The code, the seeds and the library versions are public.

The link is on this slide.

Sí. Datos gratis; código, semillas y versiones públicos. El enlace está en esta diapositiva.

Baruc Si oyes: **future work · next steps · what now**

What is the next step?

We want more stocks and sectors, longer horizons, and richer data, like news.

We already extended the test to six years and to **2026** data.

Más acciones y sectores, otros horizontes y datos más ricos. Ya lo extendimos a seis años y a datos de 2026.

Cifras — Cifras clave

Para contestar preguntas; no se leen en la exposición

Sección 7: el benchmark (120 corridas)

Azar (random): 0.333

LR global: A 0.411 · B 0.385 · C 0.401 · promedio 0.399

XGBoost global: A 0.396 · B 0.386 · C 0.373 · promedio 0.385

Simulación de LR en B: Sharpe +0.76 · profit factor 1.21

Filtros de variables: 11 de 15 casos: mejor las 61

Variación del Sharpe: acción 15.5 % · modelo 3.4 % · partición 7.0 % · resto 74.1 %

Sección 8: el protocolo corregido (partición B)

LR: 0.404 [0.379, 0.428] · Sharpe +0.895

Los otros: CNN-LSTM 0.372 · LSTM 0.369 · XGBoost 0.359 · CNN 0.359

Diferencia de LR: +0.045 XGBoost · +0.035 LSTM · +0.031 CNN-LSTM · +0.045 CNN

Búsqueda con Optuna: 150 ensayos LR y XGBoost · 80 ensayos cada red · 17–20 hiperparámetros en las redes, 9 XGBoost, 5 LR

LR elegida: L2, C = 0.000165

Redes: pérdida de validación ≈ ln 3 = 1.099 · LSTM de 592 k a 10 k parámetros: igual

Datos

Tamaño: 7 acciones · 3,017 días cada una · 61 variables · ≈ 10,500 filas de entrenamiento en B · 1,736 filas de prueba

Particiones: entrenan 10, 6 o 4 años · validan 2024 · prueban 2025

Después del artículo (empieza con: Since we submitted the paper…)

Seis años, 2020–2025: LR 0.360 · XGBoost 0.356, sin diferencia significativa · redes 0.326–0.338

Costos de 10 puntos base: Sharpe LR +0.89 → +0.62 · XGBoost +0.46 → +0.01

Datos no vistos, 2026: LR primera con 0.346; sin diferencia significativa con XGBoost, LSTM y CNN-LSTM

2 min — Versión de 2 minutos

Solo si el moderador pide recortar. La dice una persona.

► *1 + Enter*

Good afternoon. My name is Baruc Polvo,
from the Instituto Politécnico Nacional, in Mexico City.

Our question is simple:
for daily trading signals,
do deep networks beat simple models?

Each day we predict one signal,
buy, hold or sell,
for seven big tech stocks,
with free data from Yahoo Finance.

► *5 + Enter*

We compared five models:
logistic regression, XGBoost, LSTM, CNN and CNN-LSTM.
Same data, same test year: 2025.

Logistic regression was the best on average,
with a macro F1 of **zero point three nine nine**. 0.399

► *9 + Enter*

Then we gave all five models
the same hyper-parameter search tool.
The gap did not close.

Logistic regression got **zero point four zero four**, 0.404
significantly better than the other four models.

► *11 + Enter*

Three messages.
One: a simple linear model is hard to beat here.

Two: do not filter the features before training.
Three: the stock matters more than the model.

Thank you. Questions?